

程序设计实习（实验班-2026春）

稀疏性、压缩感知与线性规划方法

授课教师：姜少峰

助教：方心童、葛致远、李雷思问、刘鹏飞

Email: shaofeng.jiang@pku.edu.cn

稀疏性以及如何利用稀疏性

- 稀疏数据，例如非0/近似非0元素较少的数据，在现实中很多见
- 高维数据经常是稀疏的，这就使得Curse of Dimensionality在现实中经常不成立
- 因此有效处理稀疏数据是应对Curse of Dimensionality的重要途径

传统的利用稀疏性的框架

- 一般而言，比较自然的利用稀疏性的方法是先把数据读进来，然后
 - 利用可以处理稀疏数据的算法进行计算，例如我们的线性回归/PCA的算法
 - 利用SVD等方法进行low-rank表示
 - ...

压缩感知

Compressive Sensing


- 上述利用稀疏性的方法都是先拿到原始数据，然后再利用稀疏性进行降维/压缩
 - 但：数据本身的不少噪声/冗余本来可以不用理会的，也必须先读进来
- 可否不把数据全读进来，而是仅仅读/处理“需要的部分”？
- “压缩感知”即落实这种思想，将数据从一种“压缩”的形式中提取出来

压缩感知具体设定

- 我们设计 m 个linear measurements（线性测量） $\mathbf{a}_1, \dots, \mathbf{a}_m \in \mathbb{R}^n$
- “自然”生成一个未知的信号 $\mathbf{z} \in \mathbb{R}^n$
- 某种硬件告诉我们信号在线性测量上的值 $\mathbf{b}$, $b_1 = \langle \mathbf{a}_1, \mathbf{z} \rangle, \dots, b_m = \langle \mathbf{a}_m, \mathbf{z} \rangle$
- 仅从 $\mathbf{b}$ 恢复 $\mathbf{z}$

目标是要同一组测量 $\mathbf{a}_1, \dots, \mathbf{a}_m$,
对“所有”可能的 $\mathbf{z}$ 都要有效恢复

想象设计一个影像传感器（摄像头）
 $\mathbf{z}$ 就是真实图像， $\mathbf{b}$ 就是传感器给出的测量值



建模成矩阵

设 $\mathbf{A} = \begin{bmatrix} -\mathbf{a}_1- \\ -\mathbf{a}_2- \\ \vdots \\ -\mathbf{a}_m- \end{bmatrix}$, 硬件给出的观测是 $\mathbf{b} \in \mathbf{R}^m$, 满足 $\mathbf{b} = \mathbf{A}\mathbf{z}$

如何设计 $\mathbf{A}$ 来恢复出 $\mathbf{z}$?

等价于解线性方程（组）

- 注意到问题等价于求解 $\mathbf{x}$ ，使得 $\mathbf{Ax} = \mathbf{b}$
- 首先， $\mathbf{x} = \mathbf{z}$ 一定是这个方程的解，因为观测 $\mathbf{b}$ 保证有 $\mathbf{Az} = \mathbf{b}$
- 因此，如果 $m = n$ 应该就能精确解出 $\mathbf{z}$

$\mathbf{z}$ 有 n 维，因此 n 个方程 n 个未知数有唯一解
此时可以取 $\mathbf{A} = \mathbf{I}_n$ ，即全1对角阵

但 $m < n$ 会怎样?

- 一般来说如果 $m < n$ ，则 $\mathbf{Ax} = \mathbf{b}$ 为一个欠定方程
 - $\mathbf{z}$ 仍然是解，但是解不唯一！
- 这说明若 $\mathbf{z}$ 可以取任意变量，那么对于恢复 $\mathbf{z}$ 来说， $m = n$ 是必要的（也充分）
- 但是如果 $\mathbf{z}$ 是稀疏的呢？是否用 $m \ll n$ 就可以找到 $\mathbf{z}$ 呢？

z的稀疏性

- 我们的设定：设 $\mathbf{z}$ 是 k -稀疏的，即 $\mathbf{z}$ 有至多 k 个非0坐标，并且一般假定 $k \ll n$
- 例如， $\mathbf{z}$ 可以是一幅黑白图像，纯黑图像中有少数白线
 - 纯黑值 = 0
 - 白线 = 1，但总共只有 $k = O(\sqrt{n})$ 个像素
- 我们只是考虑在默认坐标下 $\mathbf{z}$ 有 k 个非0，但有时需要考虑先进行某些变换
 - 例如图像可能是灰度的，那么需要先二值化
 - 可能需要变换坐标，之后才会稀疏

压缩感知定理

提出该定理的论文可参考[Donoho, IEEE Trans. Inf 2006]
和[Candes-Romberg-Tao, IEEE Trans. Inf 2006]

定理：设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 其中 $m = O(k \log(n/k))$ 且 $\mathbf{A}$ 的每个元素都从 $\mathcal{N}(0,1)$ 独立采样。则 $\mathbf{A}$ 以高概率，同时对所有的 n 维的 k -稀疏的 $\mathbf{z}$ ，“可以”从观测 $\mathbf{b} = \mathbf{A}\mathbf{z}$ 中精确恢复 $\mathbf{z}$

这个版本暂时没有告知如何才能恢复，只是告知了 $\mathbf{A}$ 如何选取

即使对于1维，也有无穷多种可能性
这里强调同一个 $\mathbf{A}$ 可对所有这些无穷种情况同时奏效

定理证明不在本课程范畴；我们讨论如何理解、应用

可以扩展到近似稀疏性吗？

- 该定理的保证其实也对“近似” k -稀疏的 $\mathbf{z}$ “成立”
 - 近似 k -稀疏： $\mathbf{z}$ 中最大的 k 个元素的绝对值和“远大于”其余元素的绝对值和
- 如果 $\mathbf{z}$ 是近似稀疏的，那么设恢复出来的是 $\mathbf{z}'$ ，则 $\mathbf{z}'$ 只是近似等于 $\mathbf{z}$
 - 有时这个 $\mathbf{z}'$ 还“更好”，因为大体是去噪声后的 $\mathbf{z}$
- $\mathbf{z}'$ 与 $\mathbf{z}$ 间的误差随着 $\mathbf{z}$ 远离 k -稀疏而越来越大
 - 注意返回的 $\mathbf{z}'$ 永远是 k -稀疏的
- 极端情况： $\mathbf{z}$ 完全不稀疏，则返回的 $\mathbf{z}'$ 甚至可以与 $\mathbf{z}$ “毫无关系”

需要的观测次数可以改进吗？

- 需要的线性观测次数 $m = O(k \log(n/k))$ 是基本不可改进/最优的
- 这个量是哪来的？一些直觉/类比：
 - 考虑基于比较的排序： n 个元素有 $n!$ 种排列，排序就是确定是哪一种排列
 - 每次比较可以排除一半可能性，总共就是 $\log(n!) = O(n \log n)$ 次

类比：共有 $\binom{n}{k}$ 个不同非0位置，每个线性观测去掉一半，需要

$$\log \binom{n}{k} = O(k \log(n/k))$$

实际情况更复杂，因为观测值是实数，未必可以直接看作大于/小于这种2元情况

给定“好”的 A ，如何恢复 z ？

转化成优化问题

- 压缩感知定理只是告诉我们如何选取 $\mathbf{A}$ ，但之后如何恢复 $\mathbf{z}$ 呢？
 - 回忆： $m < n$ 时 $\mathbf{Ax} = \mathbf{b}$ 没有唯一解
- 思路：找非零坐标最少的 $\mathbf{x}$
- 优化问题：

$$\begin{array}{ll} \min & |\text{supp}(\mathbf{x})| \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \end{array}$$

$\text{supp}(\mathbf{x})$ 表示 $\mathbf{x}$ 中非零坐标的集合
 $|\text{supp}(\mathbf{x})|$ 就是非零坐标的个数

关于 $|\text{supp}(\mathbf{x})|$

$|\text{supp}(\mathbf{x})|$ 又叫做 $\mathbf{x}$ 向量的 ℓ_0 -范数

即非0的坐标个数，可以理解成 $\sum_i \mathbb{I}(x_i \neq 0)$ ，即非零都计贡献1

类比 ℓ_2 : $\|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$

上页的优化问题也叫做 ℓ_0 -最小化问题

ℓ_0 -最小化问题的求解?

- 但是 ℓ_0 -最小化问题是NP-hard的，也就是不能期望有多项式时间算法
- Idea: 将 ℓ_0 “替换”成一种不NP-hard的，但又和 ℓ_0 足够接近的目标
- 我们选取: ℓ_1

• 回忆 ℓ_1 的定义: $\|\mathbf{x}\|_1 = \sum_i |x_i|$

即每个坐标的绝对值求和
注意这个绝对值!

压缩感知定理：精确版

定理：设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 其中 $m = O(k \log(n/k))$ 且 $\mathbf{A}$ 的每个元素都从 $\mathcal{N}(0,1)$ 独立采样。则 $\mathbf{A}$ 以高概率，同时对所有的 n 维的 k -稀疏的 $\mathbf{z}$ ，下面问题的唯一最优解恰好等于 $\mathbf{z}$ ：

$$\begin{aligned} \min \quad & \|\mathbf{x}\|_1 \\ \text{s.t.} \quad & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

为什么选 ℓ_1 ?

- ℓ_1 同时满足下面两个要求
 1. 最小化 $\mathbf{x}$ 的 ℓ_1 -范数大致对应于寻找稀疏/1最少的 $\mathbf{x}$
 2. ℓ_1 最小化问题可以高效求解
- 作为对比: ℓ_0 满足1但不满足2, ℓ_2 满足2但不满足1

对比 ℓ_1 : ℓ_p -最小化问题的几何行为

为更好地理解 ℓ_1 的好处, 这里对于几个典型 p 对比 ℓ_p -最小化问题最优解的行为

$$\min \quad \|\mathbf{x}\|_p$$

ℓ_p -最小化

$$\text{s.t.} \quad \mathbf{Ax} = \mathbf{b}$$

典型的 p : $p = 1, 2, \infty$

回忆 ℓ_∞ : $\|x\|_\infty = \max_i |x_i|$

ℓ_0 不作讨论: ℓ_0 虽然称作范数但并不是真正的范数




- 没有齐次性: $\|a\mathbf{x}\|_0 \neq |a| \|\mathbf{x}\|_0$

齐次性需要这里对任何 a 都取等号


考虑二维的例子

$$\begin{array}{ll}\min & \|\mathbf{x}\|_p \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b}\end{array}$$

- $\{\mathbf{x} : \mathbf{Ax} = \mathbf{b}\}$ 是所有可行解的区域
- 考虑下面的例子：2维，且可行解区域就是一条直线，那么 $\min \|x\|_p$ 如何取到？
- 从原点出发“吹 ℓ_p 气球”，问气球第一次碰到线的 ℓ_p 半径是多少



二维例子的最优解： ℓ_p 球增长最快的方向



- ℓ_2 : 每个方向均匀增长，并不会考虑稀疏性；最优解通常稠密
- ℓ_∞ : 增长最快的是东北角，对应于全1向量，不稀疏
- ℓ_1 : 增长最快的是坐标轴方向，只有一个非零，很稀疏

ℓ_1 -最小化一般对应于稀疏解

ℓ_p 之间的关系

ℓ_∞ 可以表示一切 n 点的距离，但维度 $= n$

- 考虑 n 个数据点 $(x_1, \dots, x_n)$

叫做Fréchet's Embedding

- 定义 $f(x_i) = (f_1(x_i), \dots, f_n(x_i))$ ，其中 $f_k(x_i) = d(x_k, x_i)$

- 验证：

$$\begin{aligned}\|f(x_i) - f(x_j)\|_\infty &= \max_k |f_k(x_i) - f_k(x_j)| = \max_k |d(x_k, x_i) - d(x_k, x_j)| \\ &= d(x_i, x_j)\end{aligned}$$

最后的等号为什么？

ℓ_1 “包含” ℓ_2

- d 维的 ℓ_2 可以用 $O(d)$ 维的 ℓ_1 保 $(1 \pm \epsilon)$ 倍距离表示

类似于 JL

2.5.2 Lemma (Random projection from ℓ_2 to ℓ_1). *Let n, k be natural numbers, let $\epsilon \in (0, 1)$, and let us define a random linear map $T: \mathbb{R}^n \rightarrow \mathbb{R}^k$ by*

$$T(\mathbf{x})_i = \frac{1}{\beta k} \sum_{j=1}^n Z_{ij} x_j, \quad i = 1, 2, \dots, k,$$

where the Z_{ij} are independent standard normal random variables, and $\beta > 0$ is a certain constant ($\sqrt{2/\pi}$ if you must know). Then for every vector $\mathbf{x} \in \mathbb{R}^n$ we have

$$\text{Prob} \left[(1 - \epsilon) \|\mathbf{x}\|_2 \leq \|T(\mathbf{x})\|_1 \leq (1 + \epsilon) \|\mathbf{x}\|_2 \right] \geq 1 - 2e^{-c\epsilon^2 k},$$

where $c > 0$ is a constant.

任何度量空间映射到 ℓ_p : Bourgain's Embedding

- 设原空间为 (P, dist) 。算法：
 - 设 $t, m = \Theta(\log n)$
 - 对 $i \in [t], j \in [m]$, 计算 A_{ij} : 将每个数据点以 $1/2^j$ 概率留下
 - $f(x) := \bigoplus_{i,j} \text{dist}(x, A_{ij})$
- 结论是 $O(\log n)$ -distortion: $\|f(x) - f(y)\|_1 \leq mt \cdot \text{dist}(x, y)$ 总成立
- 但另一边 $\|f(x) - f(y)\|_1 \geq \Omega(m) \cdot \text{dist}(x, y)$ 是 (高) 概率的

这里考虑的是 ℓ_1

求解 ℓ_1 -最小化问题：
线性规划

线性规划

Linear programming (LP)

关于术语：一般指代线性规划方法用linear programming，但具体指一个优化问题用linear program，与dynamic program/programming类似

- 变量： $x_1, \dots, x_n \in \mathbb{R}$ ，可以自由变化，LP可以自动找到一组最优的 x

- 约束： 必须是线性约束，形如 $\sum_{j=1}^n a_{ij}x_j \leq b_i$

大于等于可以加负号实现；
等于可以小于等于 + 大于等于实现

- 目标函数： 必须是线性的，形如 $\min \sum_{j=1}^n c_j x_j$

max可以加负号实现

- 非线性的，例如 x_j^2 ， $x_j x_k$ ， $\log(1 + x_j)$ 这些都不允许

线性规划的意义

- 线性规划是可以高效求解的
 - 理论上：存在最坏情况多项式时间算法
 - 实用上：形成了非常高效的solver
- 线性规划可以用来建模/近似求解非常广泛的问题


很多国家政府、企业、军队等都认识到LP的重要意义，几十年来的solver研发使得求解十分高效

由于其达到了很好的通用性和可计算性，是最重要的工具之一

一个简单例子与求解

$$\begin{array}{ll}\max & x_1 + x_2 \\ \text{s.t.} & x_1 \geq 0 \\ & x_2 \geq 0 \\ & 2x_1 + x_2 \leq 1 \\ & x_1 + 2x_2 \leq 1\end{array}$$

总体intuition: 目标函数定义了优化的“方向”
目标就是在可行域里面找“优化方向”上的最远点



如何求解线性规划：理论上

- 理论上：存在多项式时间算法，例如ellipsoid method
- 假定存在一个单位时间可以调用的separation oracle，要求
 - 输入一组解，如果该解可行，那么输出Yes
 - 否则输出No，并给出一条不满足的约束
- ellipsoid method调用多项式次separation oracle以及进行多项式次其他操作

* 用Separation Oracle可以解一些“奇怪”的LP

- Ellipsoid配合separation oracle可能可以求解某些巨大的LP
- 巨大：变量有 $\text{poly}(n)$ 个，然而约束有 $\exp(n)$ 个

$$\min \sum_{e \in E} c_e x_e$$

给定图 $G = (V, E)$, $e \in E$ 边权 c_e , 该LP“代表”的是最小生成树

$\delta(S)$ 就是 S 个割边集

$$\text{s.t.} \quad \sum_{e \in \delta(S)} x_e \geq 1, \forall S \subset V$$

这约束的意思是，只要 S 不等于全集 V ，那么就必须选择一些跨越 S 的边，来保证连通性

$$x_e \in [0, 1], \quad \forall e \in E$$

虽然对MST本身没什么意义，但这类LP及其求解在带连通性约束的网络设计问题的近似算法研究中居于核心地位

对MST是2-近似，但同时对于斯坦纳树也是2-近似

问题：如何设计separation oracle？即如何判定给定的 $\mathbf{x}$ 是可行解？

如何求解线性规划：实用上

- 实用上，ellipsoid method并不是最快的
- 相反，一种古老的称作simplex method的算法实际中表现很好
 - 但simplex method的最坏时间复杂度非常高，可以是 $\exp(n)$ 的！
 - 因此这侧面说明实际上一般遇不到最坏情况

对Simplex Method实际情况表现好的理论解释

奖给最杰出的理论计算机科学论文（的作者）

- [Spielman-Teng, JACM 04], Gödel Prize 哥德尔奖

- 我们一般考虑算法时间复杂度都是考虑最坏情况

提出了smoothed analysis框架，并且应用在了单纯形法等重要常用算法

- Smoothed analysis中，假设输入并非最坏

- 而是任意一个输入再加上一个随机噪声

- ST04证明的是在期望意义下，单纯形法是多项式时间复杂度

随机性来自于噪声

完美契合了实际情况：实际上LP的输入都有噪声

实际该使用的：成熟的Solver软件/类库

- 刚刚的讨论主要停留在理论上

自己实现的很难比得上solver的，因为solver的实现是无数特例研究/工程优化等的结果

- 真正要解LP，还是要尽量使用已经实现好的成熟solver
 - 商业求解器：CPLEX, Gurobi
 - 开源求解器：GLPK (GNU Linear Programming Kit), Ip_solve, CVXPY
 - 一些软件/类库带的求解器：Matlab, Mathematica, numpy/scipy

lp_solve

- 性能中等，开源，较易使用的LP solver（也支持整数规划！）
- <https://lpsolve.sourceforge.net/>
- 安装后可以使用命令行工具lp_solve LP_FILE.lp
- LP_FILE的格式、样例：<https://lpsolve.sourceforge.net/5.5/lp-format.htm>

```
/* xxx.lp */  
  
max: 143 x + 60 x1;  
  
120 x + 210 x1 <= 15000;  
110 x + 30 x1 <= 4000;  
x + x1 <= 75;
```

xxx.lp文件

Value of objective function: 6315.62500000

Actual values of the variables:

x	21.875
x1	53.125

运行lp_solve xxx.lp

注释

```
/* xxx.lp */
```

优化objective, 可选max或min

```
max: 143 x + 60 x1;
```

变量命名规则类似C/C++, 支持浮点数系数

这些是约束, 可以用<, <=, >, >=, =

```
120 x + 210 x1 <= 15000;
```

```
110 x + 30 x1 <= 4000;
```

```
x + x1 <= 75;
```

不要忘记给变量设置范围: 默认是 $[0, +\infty)$; 如果要 $(-\infty, +\infty)$ 可以写free x1

回到主题：如何用LP求解 ℓ_1 -最小化问题？

$$\begin{array}{ll}\min & \|\mathbf{x}\|_1 \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b}\end{array}$$

- 如何转化成LP？

因为有绝对值！

• $\mathbf{Ax} = \mathbf{b}$ 已经是线性约束了，但 $\|\mathbf{x}\|_1 = \sum_i |x_i|$ 并不是线性的

- 先考虑一个简单情况：若真实信号 $\mathbf{z}$ 每维 ≥ 0 ，则可仅考虑 $\mathbf{x} \geq 0$ 的情况，得到

$$\begin{array}{ll}\min & \|\mathbf{x}\|_1 = \sum_i x_i \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq 0\end{array}$$

有 $x_i \geq 0$ 的假设，此处可去掉绝对值

一般情况：如何处理绝对值

添加辅助变量 y 来刻画“绝对值”，改写成

$$\begin{aligned} \min \quad & \sum_i y_i \\ \text{s.t.} \quad & \mathbf{Ax} = \mathbf{b} \\ & y_i - x_i \geq 0, \quad \forall i \\ & y_i + x_i \geq 0, \quad \forall i \end{aligned}$$

否则若 $y_i > |x_i|$ 则可以降低 y_i 到 $y_i = |x_i|$ ，不影响其他任何变量，但降低了目标值

在这个新LP中：对每个 i ，有 $y_i \geq |x_i|$ ，并且由于目标是min，必然有 $y_i = |x_i|$

小扩展：输入有噪声

- 线性规划一般可以轻易处理有噪声的情况
- 例如，我们收到的不是精确的 $\mathbf{b} = \mathbf{A}\mathbf{z}$ ，而是收到一个 $\hat{\mathbf{b}}$
 - 每个维度上 $\hat{b}_i \in [b_i - \epsilon, b_i + \epsilon]$
- 如果把 $\hat{\mathbf{b}}$ 当 $\mathbf{b}$ 来用，甚至可能导致LP无解

对每个 $1 \leq i \leq m$ 都需要有

解决方案：将 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 换成 $\sum_{j=1}^n a_{ij}x_j \leq b_i + \epsilon$ 和 $\sum_{j=1}^n a_{ij}x_j \geq b_i - \epsilon$ 两组

压缩感知定理也有对应的带噪声的版本

基于压缩感知的Sparse Recovery: 完整算法

- 预先给定的参数: k, n , 代表信号是 n 维的 k -稀疏的实向量
- 算法先生成一个 $m \times n$ 的随机高斯矩阵 $\mathbf{A}$, 其中 $m = O(k \log(n/k))$
- 算法得到 $\mathbf{b} \in \mathbb{R}^m$, 使得 $\mathbf{b} = \mathbf{A}\mathbf{z}$
- 算法继续计算右边LP的最优解 $\mathbf{x}$ 作为输出

每一维都是独立标准正态 $\mathcal{N}(0,1)$

压缩感知定理告诉我们大概率有 $\mathbf{x} = \mathbf{z}$

$$\begin{aligned} \min \quad & \sum_i y_i \\ \text{s.t.} \quad & \mathbf{Ax} = \mathbf{b} \\ & y_i - x_i \geq 0, \quad \forall i \\ & y_i + x_i \geq 0, \quad \forall i \end{aligned}$$

作业二十一：压缩感知实验报告

- 本次作业为实验报告，具体要求请见下面链接中的PDF文档：

https://chinapku-my.sharepoint.com/:b:/g/personal/2106190107_pku_edu_cn/ESqzdkLG-JxAmqc1b_bUJoEBZxSmnCDweitceUTmsKTk8g?e=ElKjcJ

作业需要调用一个解LP的算法

- 可以使用任何solver

本次实验报告不限制编程语言和LP solver

- 分值：3分；截止日期：6月17日，请提交到教学网！

单纯形法简介： 举例讲解

参考： <https://math.mit.edu/~goemans/18310S15/lpnotes310.pdf>

预处理：转化成“标准型”

- 标准型的要求：目标是max，约束只有等式，所有变量非负
- 转换方法：
 - 如果目标是min z ，则转成 $\max - z$
 - 如果约束是 $a_{i1}x_1 + \dots + a_{in}x_n \leq b_i$ ，引入非负松弛变量 s_i ，改成两个约束： $s_i \geq 0$ ，以及 $a_{i1}x_1 + \dots + a_{in}x_n + s_i = b_i$
 - 如果有变量 x_i 没有符号约束，将它替换成 $x'_i - x''_i$ ， $x'_i \geq 0$ ， $x''_i \geq 0$

如果是 $\geq$ 应该如何操作？

转化成标准型举例

$$\min \quad -2x_1 + 3x_2$$

$$x_1 - 3x_2 + 2x_3 \leq 3$$

$$-x_1 + 2x_2 \geq 2$$

$$x_1 \in \mathbb{R}, x_2, x_3 \geq 0$$

变max, 改等号




$$\max \quad 2x_1 - 3x_2$$

$$x_1 - 3x_2 + 2x_3 + s_1 = 3$$

$$-x_1 + 2x_2 - s_2 = 2$$

$$x_1 \in \mathbb{R}, x_2, x_3, s_1, s_2 \geq 0$$

替换无符号限制变量 x_1



$$\max \quad 2(x'_1 - x''_1) - 3x_2$$

$$(x'_1 - x''_1) - 3x_2 + 2x_3 + s_1 = 3$$

$$-(x'_1 - x''_1) + 2x_2 - s_2 = 2$$

$$x'_1, x''_1, x_2, x_3, s_1, s_2 \geq 0$$

单纯形法： 举例讲解

考虑已化为标准型LP：

$$\begin{aligned} \max \quad & x_1 + x_2 \\ & 2x_1 + x_2 + x_3 = 4 \\ & x_1 + 2x_2 + x_4 = 3 \\ & x_1, x_2, x_3, x_4 \geq 0 \end{aligned}$$

得到系数矩阵/方程组

将所有等号约束以及z方程（目标函数）放在一起得到一个方程组

$$\begin{array}{cccccccl} z & -x_1 & -x_2 & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = & 3 & \text{Row 2} \end{array}$$

时刻注意：所有变量 $x_1, x_2, x_3, x_4 \geq 0$ ，要寻找的是最大的 z

额外要求

$$\begin{array}{cccccccl} z & -x_1 & -x_2 & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = & 3 & \text{Row 2} \end{array}$$

m 是约束/行数

该 $\mathbf{I}_m$ 是 $m \times m$ 单位阵，从忽略Row 0的矩阵找

额外要求：等号右边都 ≥ 0 ，系数矩阵含 $\mathbf{I}_m$ 且该 $\mathbf{I}_m$ 对应的列的系数在Row 0都是0

上面的例子满足这个要求： $\mathbf{I}_m$ 是 x_3, x_4 对应的

一般如何达到该要求后面会讲解

单纯形法框架

- 从刚刚得到的满足额外要求的标准型开始，单纯形法进行若干步迭代
- 我们主要描述每次迭代需要做的算法步骤，包括：
 - 如何判定终止——终止条件即最优条件
 - 当前未终止的话，这步内部做什么

当然还有判定“无解”“有无穷多解”等各种细节，在此不讨论

定义“基本可行解”

$$\begin{array}{rcccccccl} z & -x_1 & -x_2 & & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & & = & 3 & \text{Row 2} \end{array}$$

基变量：某列上唯一系数非0的变量，这里是 x_3, x_4

非基变量：其他变量，这里是 x_1, x_2

基本可行解：将非基变量设置成0，代入后解方程得出基变量值

上面例子：非基 $x_1 = x_2 = 0$ ，基 $x_3 = 4, x_4 = 3$

将目标用非基变量表示

$$\begin{array}{rclcl} z & -x_1 & -x_2 & & = 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & = 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 = 3 & \text{Row 2} \end{array}$$

- 在这个例子中， x_1, x_2 是非基变量，Row 0已经是只有非基变量，不需要变换
 - 否则，总可以将每个基变量用非基变量线性表示，然后替换
 - 替换后Row 0只含有非基变量

重要规则1：最优解/停止判据

$$\begin{array}{rcccccccl} z & -x_1 & -x_2 & & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & & = & 3 & \text{Row 2} \end{array}$$

- 将目标Row 0用非基变量表示后，如果某变量系数是负的
 - 则一定可以增大变量值来改进 z 的值，也就是此时**非最优**
- 因此最优/停止判据：Row 0所有系数都是正的

选择某个非基作为entering变量

$$\begin{array}{rcccccl} z & -x_1 & -x_2 & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = & 3 & \text{Row 2} \end{array}$$

- 现在根据规则1不是最优解
- 下一步：选某Row 0行系数为负的非基变量作为entering（加入）变量
- 选某个行作为pivot行高斯消元
- 消元后就会有某个基变量成为非基变量，称为leaving变量

选取下标最小的（最靠左的），又叫Bland规则，用于防止一些情况下单纯形法死循环

如何进行，也就是pivot，也很重要，规则后面讲

leaving变量具体是谁不重要，也不需要我们去选择，只是可以证明有一个enter的非基变量就必有一个leaving的基变量

先假设pivot选好了：进行高斯行变换

- 选 x_1 作为加入变量，选Row 1作为pivot运行消元

$$z - x_1 - x_2 = 0 \quad \text{Row 0}$$

$$2x_1 + x_2 + x_3 = 4 \quad \text{Row 1}$$

$$x_1 + 2x_2 + x_4 = 3 \quad \text{Row 2}$$

$$z - \frac{1}{2}x_2 + \frac{1}{2}x_3 = 2 \quad \text{Row 0}$$

$$x_1 + \frac{1}{2}x_2 + \frac{1}{2}x_3 = 2 \quad \text{Row 1}$$

$$\frac{3}{2}x_2 - \frac{1}{2}x_3 + x_4 = 1 \quad \text{Row 2}$$

新的基本可行解

得到新的基本可行解就完成了一轮迭代
此时可以利用最优化/停止判据决定是否继续
若未判定停止：则继续利用刚才的规则

$$\begin{array}{rcll} z & -\frac{1}{2}x_2 & \frac{1}{2}x_3 & = 2 & \text{Row 0} \\ x_1 & +\frac{1}{2}x_2 & +\frac{1}{2}x_3 & = 2 & \text{Row 1} \\ & \frac{3}{2}x_2 & -\frac{1}{2}x_3 & +x_4 & = 1 & \text{Row 2} \end{array}$$

- 新的基变量是 x_1, x_4 ，令非基变量为0
- 得到 $x_2 = x_3 = 0, x_1 = 2, x_4 = 1, z = 2$

依然满足：等号右边都 ≥ 0 ，系数矩阵含 $\mathbf{I}_m$ 且该 $\mathbf{I}_m$ 对应的列的系数在Row 0都是0

重要规则2： 如何为entering变量选行/pivot

——补全缺失的最后一环

- 除去Row 0的行中找那些让entering变量系数严格 > 0 的，将RHS除以这个系数
- 选比值最小的行

$$\begin{array}{rcccccccl} z & -x_1 & -x_2 & & & = & 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & & = & 4 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = & 3 & \text{Row 2} \end{array}$$

- 例如，选 x_1 作为entering，Row 1比值2，Row 2比值3，应该选Row 1

为什么要选比值最小的行？选其他行会怎样？

- 比如选Row 2会怎样？

$$\begin{array}{rcll} z & -x_1 & -x_2 & = 0 & \text{Row 0} \\ & 2x_1 & +x_2 & +x_3 & = 4 & \text{Row 1} \\ & \mathbf{x_1} & +2x_2 & & +x_4 & = 3 & \text{Row 2} \end{array}$$

$$\begin{array}{rcll} z & & +x_2 & & +x_4 & = 3 & \text{Row 0} \\ & & -3x_2 & +x_3 & -2x_4 & = -2 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = 3 & \text{Row 2} \end{array}$$

看上去好像最优了？

选其他行的问题所在

单纯形法重要要求：每次的基本解必须得到可行解

$$\begin{array}{rcccccccl} z & & +x_2 & & +x_4 & = & 3 & \text{Row 0} \\ & & -3x_2 & +x_3 & -2x_4 & = & -2 & \text{Row 1} \\ & x_1 & +2x_2 & & +x_4 & = & 3 & \text{Row 2} \end{array}$$


- 此时基本解 $x_2 = x_4 = 0$, $x_1 = 3$, $x_3 = -2$, 非可行解!

本质原因：等号右边有负数
导致负数的原因是选了Row 2，比值大于Row 1

思考：为什么选了比值最小的行就能确保RHS
不会有负数了？

执行过程的几何直观

z	$-x_1$	$-x_2$	$=$	0	Row 0
	$2x_1$	$+x_2$	$+x_3$	$=$	4 Row 1
	x_1	$+2x_2$	$+x_4$	$=$	3 Row 2
z	$-\frac{1}{2}x_2$	$\frac{1}{2}x_3$	$=$	2	Row 0
	x_1	$+\frac{1}{2}x_2$	$+\frac{1}{2}x_3$	$=$	2 Row 1
	$\frac{3}{2}x_2$	$-\frac{1}{2}x_3$	$+x_4$	$=$	1 Row 2
z		$+\frac{1}{3}x_3$	$+\frac{1}{3}x_4$	$=$	$\frac{7}{3}$ Row 0
	x_1	$+\frac{2}{3}x_3$	$-\frac{1}{3}x_4$	$=$	$\frac{5}{3}$ Row 1
	x_2	$-\frac{1}{3}x_3$	$+\frac{2}{3}x_4$	$=$	$\frac{2}{3}$ Row 2



“去掉”额外要求

额外要求：等号右边都 ≥ 0 ，系数矩阵含 $\mathbf{I}_m$ 且该 $\mathbf{I}_m$ 对应的列的系数在 Row 0 都是 0

先定义一个辅助的所谓的“Phase I 问题”

对每个非 Row 0 的 Row i ：若 $b_i < 0$ 则两边先取负

- 引入一个新变量 t_i ，系数是 1，加在这一行上

- 将目标函数改为 $\min \sum_i t_i$ ，并替换掉以前的 Row 0

这个新问题中，最优解一定是所有 $t_i = 0$ ，最优值 = 0


举例

max $2x_1 + 3x_2 + 4x_3$
 $3x_1 + 2x_2 + x_3 = 10$
 $2x_1 + 5x_2 + 3x_3 = 15$
 $x_1, x_2, x_3 \geq 0$

写成方程组



z	$-2x_1$	$-3x_2$	$-4x_3$	$=$	0	Row 0
	$3x_1$	$+2x_2$	$+x_3$	$=$	10	Row 1
	$2x_1$	$+5x_2$	$+3x_3$	$=$	15	Row 2



加入辅助变量、改成新的目标

z				$-t_1$	$-t_2$	$=$	0	Row 0
	$3x_1$	$+2x_2$	$+x_3$	$+t_1$		$=$	10	Row 1
	$2x_1$	$+5x_2$	$+3x_3$		$+t_2$	$=$	15	Row 2

还差一小步

- 在这个新问题中，还需要将每个Row i ($i \geq 1$)加到Row 0上才满足额外要求

z				$-t_1$	$-t_2$	$=$	0	Row 0
	$3x_1$	$+2x_2$	$+x_3$	$+t_1$		$=$	10	Row 1
	$2x_1$	$+5x_2$	$+3x_3$		$+t_2$	$=$	15	Row 2

此时得到的问题满足单纯形法所有要求!

将Row 1和Row 2加到Row 0

z	$5x_1$	$7x_2$	$4x_3$			$=$	25	Row 0
	$3x_1$	$+2x_2$	$+x_3$	$+t_1$		$=$	10	Row 1
	$2x_1$	$+5x_2$	$+3x_3$		$+t_2$	$=$	15	Row 2

Phase I问题和Phase II问题

回忆：此时的最优解一定是让辅助变量 t_i 都等于0的解

- 在刚才的新的Phase I问题上用单纯形法求解，直到得到最优解
 - 若所有辅助变量都是非基，则可以都删除，剩下的原变量满足额外要求
- 否则：存在一个辅助基变量 t_i ，此时基本解中 $t_i = 0$ ，这推出 $b_i = 0$
- 随便挑选一个第 i 行系数非0的原变量 x_j 为pivot进行变换

这里假定唯一系数非零的 t_i 出现在第 i 行， b_i 是对应的RHS

反复运行后，就可以让所有辅助变量称为非基变量

因为 $b_i = 0$ ，不会对解产生任何影响，但却可以将 t_i 变成非基

- 之后可以在原问题上照常运行单纯形法（称为Phase II）

额外要求：等号右边都 ≥ 0 ，系数矩阵含 $\mathbf{I}_m$ 且该 $\mathbf{I}_m$ 对应的列的系数在Row 0都是0